10X单细胞数据上游分析流程

欧阳继华

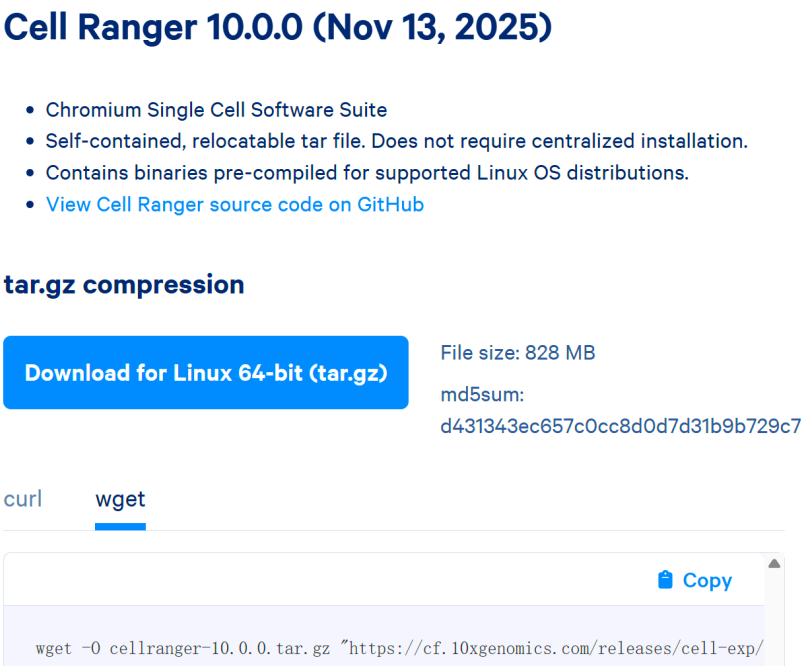
2025年3月

10X单细胞数据上游分析流程
- 1 Cell Ranger安装
- 2 准备参考基因组数据
  - 2.1 预建参考基因组
  - 2.2 自建参考基因组
- 3 准备测序数据文件
  - 3.1 由BCL文件转fastq文件
  - 3.2 直接使用已有的fastq文件
- 4 运行cellranger count
- 5 输出文件
- 6 细胞自动注释
- 7 使用示例

---

1 Cell Ranger安装

进入[10X官网下载中心]下载相应版本的Cell Range软件。



将相关路径添加至环境变量中：

```
export PATH=/opt/cellranger-x.y.z:$PATH
```

运行出现如下界面即表示程序成功安装：

```
$ cellranger -h
cellranger 10.0.0

Process 10x Genomics Gene Expression, Feature Barcode, and Immune Profiling data

Usage: cellranger <COMMAND>

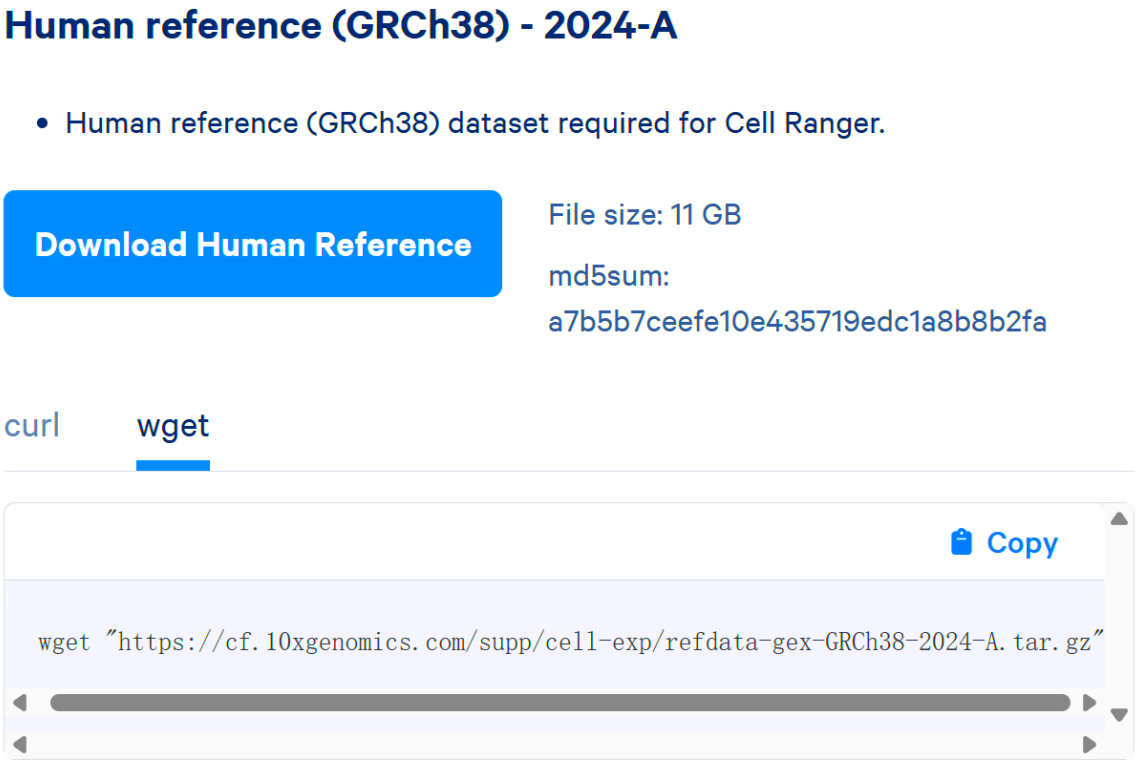
Commands:
  count           Count gene expression and/or feature barcode reads from a single sample and GEM well
  multi           Analyze multiplexed data or combined gene expression/immune profiling/feature barcode data
  multi-template  Output a multi config CSV template
  vdj             Assembles single-cell VDJ receptor sequences from 10x Immune Profiling libraries
  aggr            Aggregate data from multiple Cell Ranger runs
  annotate        Annotate cell-types from outputs of a CellRanger run
  reanalyze       Re-run secondary analysis (dimensionality reduction, clustering, etc)
  mkvdjref        Prepare a reference for use with CellRanger VDJ
  mkfastq         Run Illumina demultiplexer on sample sheets that contain 10x-specific sample index sets
  testrun         Execute the 'count' pipeline on a small test dataset
  cloud           Invoke cloud commands
  mat2csv         Convert a feature-barcode matrix to CSV format
  mkref           Prepare a reference for use with 10x analysis software. Requires a GTF and FASTA
  mkgtf           Filter a GTF file by attribute prior to creating a 10x reference
  upload          Upload analysis logs to 10x Genomics support
  sitecheck       Collect Linux system configuration information
  telemetry       Configure and inspect telemetry settings and data
  help            Print this message or the help of the given subcommand(s)

Options:
  -h, --help     Print help
  -V, --version  Print version
```

2 准备参考基因组数据

2.1 预建参考基因组

对于常见物种（**人，小鼠，大鼠**），10X官方提供了预先构建好的参考基因基因组，直接在[下载中心]下载解压即可使用。



2.2 自建参考基因组

10X官方同样支持用户自行构建参考基因组，并给出了[自建流程]。

这里以**斑马鱼**参考基因组构建为例进行构建流程的展示。

1. 在**ENSEMBL**或其他基因组数据库下载斑马鱼的基因组和GTF文件

```
wget -c https://ftp.ensembl.org/pub/release-115/fasta/danio_rerio/dna/Danio_rerio.GRCz11.dna.primary_assembly.fa.gz

wget -c https://ftp.ensembl.org/pub/release-115/gtf/danio_rerio/Danio_rerio.GRCz11.115.gtf.gz
```

> ⚠ **Warning**
>
> **基因组注释文件只支持GTF格式，不支持GFF格式，如果只有GFF可以借助其他工具进行转换成GTF**

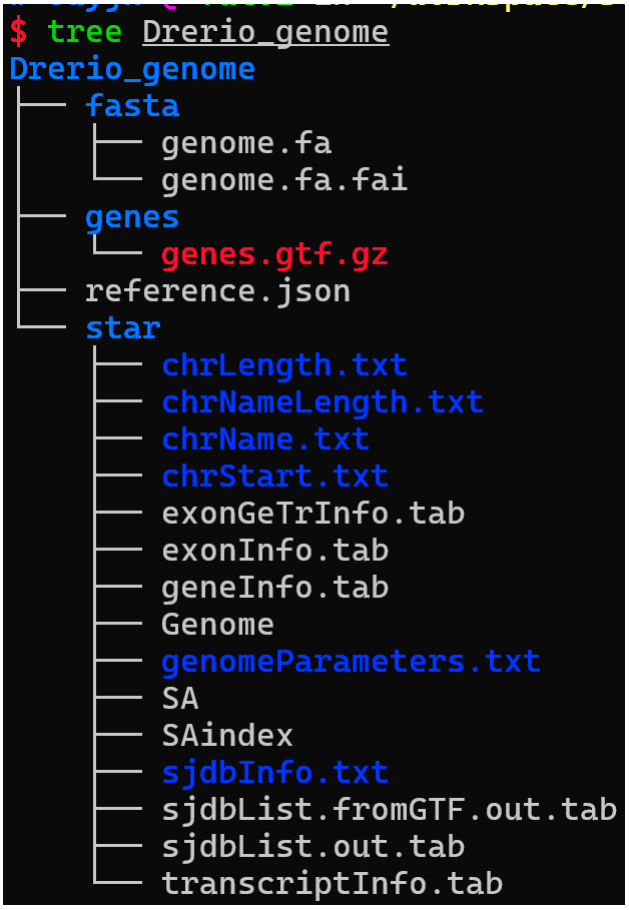
2. 对GTF文件进行过滤，筛选出需要的基因类型。

```
cellranger mkgtf \
     Danio_rerio.GRCz11.115.gtf \
     Danio_rerio.GRCz11.115.filtered.gtf \
     --attribute=gene_biotype:protein_coding
```

3. 使用过滤后的GTF文件和基因组数据来构建基因组参考文件。

```
cellranger mkref \
  --genome Drerio_genome \
  --fasta Danio_rerio.GRCz11.dna.primary_assembly.fa \
  --genes Danio_rerio.GRCz11.115.filtered.gtf \
  --nthreads 60 \
  --memgb 1000
```

搭建好的参考基因组格式如下：



3 准备测序数据文件

3.1 由BCL文件转fastq文件

10x官方开发了 `cellranger mkfastq` 工具，这是一个包装了 Illumina 的 **bcl2fastq** 程序的管道，能够让使用者方便快捷地将Illumina测序产生的BCL文件转换成下游分析可识别的fastq文件，参考页面。

1. 首先需要安装Illumina的**bcl2fastq** 程序

方法一：根据Illumina提供的官方教程安装，先去软件中心下载对应安装包，然后再根据安装指导文件进行安装。

这种方法只提供rpm安装和源码安装两种方式，对于非CentOS系统安装不太友好。

方法二（**推荐**）：使用conda安装，参考命令：

```
conda install -c bih-cubi bcl2fastq2
bcl2fastq -v
```

2. 准备好所需BCL相关文件。这里使用教程中的测序数据：

```
wget -c https://cf.10xgenomics.com/supp/cell-exp/cellranger-tiny-bcl-1.2.0.tar.gz
wget https://cf.10xgenomics.com/supp/cell-exp/cellranger-tiny-bcl-simple-
1.2.0.csv
```

下载解压后的文件格式如下：

```
# ouyjh @ fat02 in ~/Workspace/scRNA_cellranger_pipeline/Fastq [11:55:30] (base)
$ ls cellranger-tiny-bcl-1.2.0
Config  Data  InterOp  RTAComplete.txt  RunInfo.xml  runParameters.xml

# ouyjh @ fat02 in ~/Workspace/scRNA_cellranger_pipeline/Fastq [11:55:59] (base)
$ head cellranger-tiny-bcl-simple-1.2.0.csv
Lane,Sample,Index
1,test_sample,SI-P03-C9
```

3. 运行 `cellranger mkfastq` 产生fastq文件

```
cellranger mkfastq --id=tiny-bcl \
             --run=/path/to/tiny_bcl \
             --csv=cellranger-tiny-bcl-simple-1.2.0.csv
```

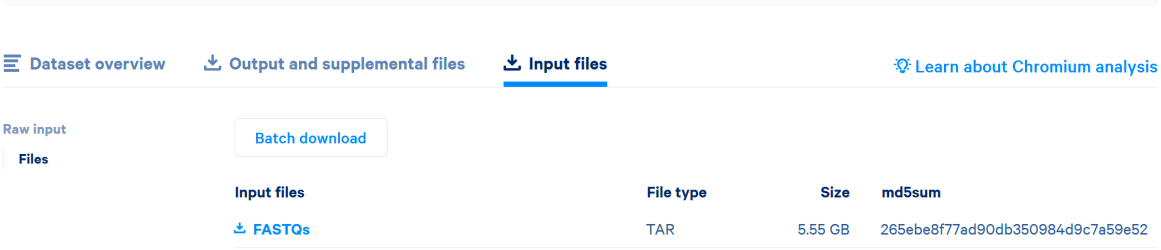
最终产生的fastq文件在以输入id指定的文件夹内，具体位置如图：

```
# ouyjh @ fat02 in ~/Workspace/scRNA_cellranger_pipeline/Fastq [15:02:15] (base)
$ ls tiny-bcl/outs/fastq_path/H35KCBCXY/test_sample -lh
total 16K
-rw-rw-r-- 1 ouyjh ouyjh 1.5K Mar  3 11:09 test_sample_S1_L001_I1_001.fastq.gz
-rw-rw-r-- 1 ouyjh ouyjh 2.9K Mar  3 11:09 test_sample_S1_L001_R1_001.fastq.gz
-rw-rw-r-- 1 ouyjh ouyjh 7.1K Mar  3 11:09 test_sample_S1_L001_R2_001.fastq.gz
```

3.2 直接使用已有的fastq文件

如果得到的数据是现成的fastq数据（例如来自公共数据库），则无需进行转化，可以直接使用。

10X官方提供了**官方的测序数据库**，在这里使用其中的**1k PBMCs**数据集进行使用。



直接下载fastq文件用于后续分析流程。

```
$ ll -h pbmc_1k_v3_fastqs
total 5.2G
-rw-r--r-- 1 ouyjh ouyjh 245M Nov  2  2018 pbmc_1k_v3_S1_L001_I1_001.fastq.gz
-rw-r--r-- 1 ouyjh ouyjh 719M Nov  2  2018 pbmc_1k_v3_S1_L001_R1_001.fastq.gz
-rw-r--r-- 1 ouyjh ouyjh 1.7G Nov  2  2018 pbmc_1k_v3_S1_L001_R2_001.fastq.gz
-rw-r--r-- 1 ouyjh ouyjh 243M Nov  2  2018 pbmc_1k_v3_S1_L002_I1_001.fastq.gz
-rw-r--r-- 1 ouyjh ouyjh 714M Nov  2  2018 pbmc_1k_v3_S1_L002_R1_001.fastq.gz
-rw-r--r-- 1 ouyjh ouyjh 1.7G Nov  2  2018 pbmc_1k_v3_S1_L002_R2_001.fastq.gz
```

4 运行cellranger count

使用`cellranger count`参数进行上游分析，参考命令如下：

```
cellranger count \
    --id=run_count_1kpbmcs \
    --
fastqs=/oldhome/ouyjh/Workspace/scRNA_cellranger_pipeline/Fastq/pbmc_1k_v3_fastqs
\
    --sample=pbmc_1k_v3 \
    --create-bam true \
    --localcores 48 \
    --localmem 1000 \
    --
transcriptome=/oldhome/ouyjh/Workspace/scRNA_cellranger_pipeline/References/refda
ta-gex-GRCh38-2024-A
```

官方文档给出了所有参数及其含义，这里用到的主要参数说明：

参数	作用
`--id`	指定运行的唯一标识符（ID），该 ID 用作输出目录的名称。
`--fastqs`	指定包含 FASTQ 文件的目录路径，Cell Ranger 会从该目录读取输入的 FASTQ 文件。
`--sample`	指定要使用的样本名，用于从多个样本的 FASTQ 文件中选择特定的样本。
`--create-bam`	启用或禁用 BAM 文件生成。设置为 `true` 会生成 BAM 文件。
`--localcores`	指定本地计算时要使用的最大 CPU 核心数，用于并行处理。
`--localmem`	指定本地计算时要使用的最大内存，单位为 GB。
`--transcriptome`	指定包含转录组参考数据的文件夹路径，用于基因表达量计数。

运行时间取决于数据量大小，上述的pbmc_1k_v3数据集运行时间约为**30min**。运行成功后输出结果的目录如下：

```
# ouyjh @ fat02 in ~/Workspace/scRNA_cellranger_pipeline [9:49:15] (base)
$ ll run_count_1kpbmcs/outs -h
total 4.1G
drwxrwxr-x 7 ouyjh ouyjh   98 Mar  3 17:10 analysis
-rw-rw-r-- 2 ouyjh ouyjh  31M Mar  3 17:17 cloupe.cloupe
drwxrwxr-x 2 ouyjh ouyjh   89 Mar  3 17:09 filtered_feature_bc_matrix
-rw-rw-r-- 1 ouyjh ouyjh 6.0M Mar  3 17:09 filtered_feature_bc_matrix.h5
-rw-rw-r-- 1 ouyjh ouyjh  677 Mar  3 17:16 metrics_summary.csv
-rw-rw-r-- 1 ouyjh ouyjh  66M Mar  3 17:10 molecule_info.h5
-rw-rw-r-- 1 ouyjh ouyjh 4.0G Mar  3 17:07 possorted_genome_bam.bam
-rw-rw-r-- 1 ouyjh ouyjh 3.9M Mar  3 17:07 possorted_genome_bam.bam.bai
drwxrwxr-x 2 ouyjh ouyjh   89 Mar  3 17:05 raw_feature_bc_matrix
-rw-rw-r-- 1 ouyjh ouyjh  10M Mar  3 17:05 raw_feature_bc_matrix.h5
-rw-rw-r-- 1 ouyjh ouyjh 5.1M Mar  3 17:16 web_summary.html
```

> **Important**
>
> `cellranger count`也提供了`--force-cells`参数用于强制指定生成的细胞数量

5 输出文件

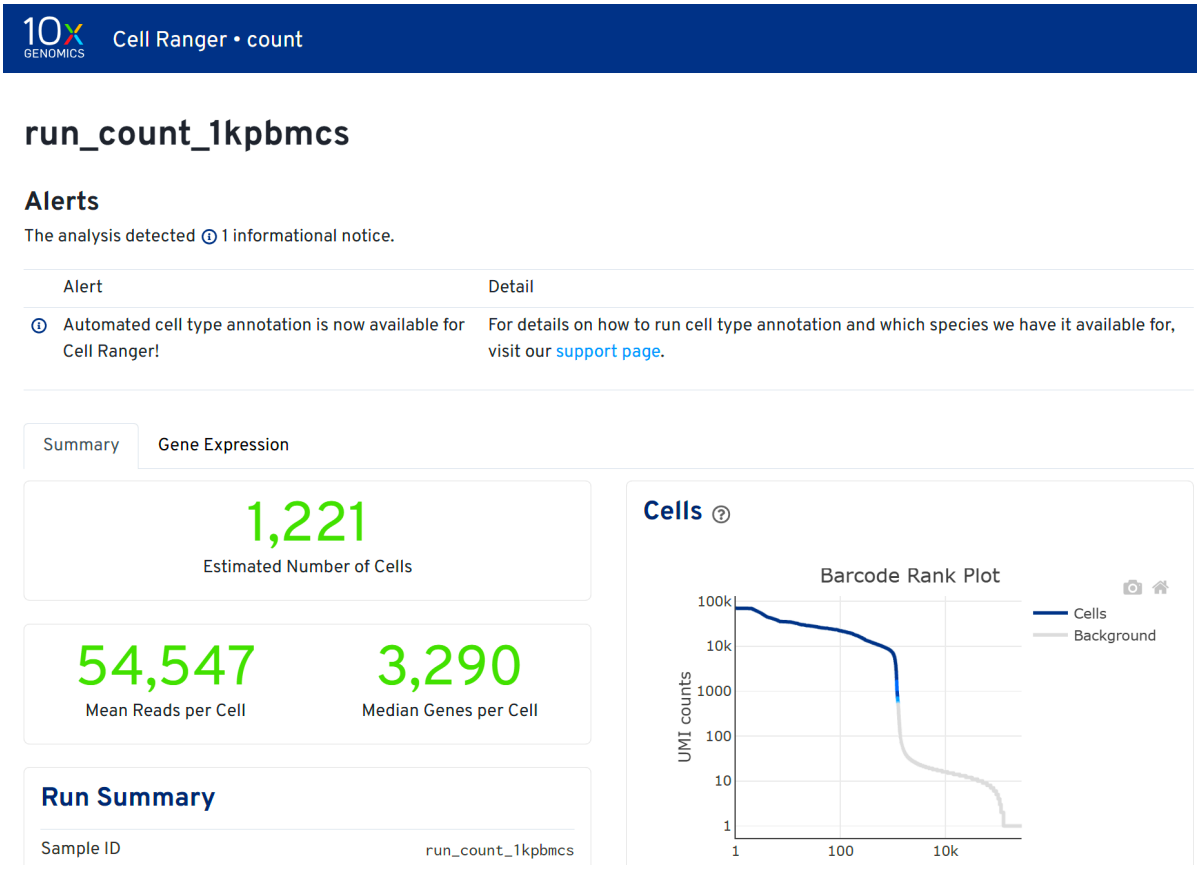
官方文档中给出了`cellranger count`程序的输出内容，同时具体解释了各个输出文件的含义。

文件/文件夹	描述
`analysis/`	包含基于图的聚类结果和 K-means 聚类（2–10 类）；簇间差异基因表达分析；以及 PCA、t-SNE 和 UMAP 等降维分析结果的文件夹。
`cloupe.cloupe`	用于 Loupe Browser 的可视化与分析文件。
`filtered_feature_bc_matrix/`	仅包含检测到的、与细胞相关的条形码（barcode），采用 MEX 格式。矩阵中的每个元素表示某个特征（行）与某个条形码（列）对应的 UMI 数量。该文件可作为第三方分析软件的输入，用于处理条形码-特征矩阵（例如过滤异常细胞、运行降维分析、进行基因表达归一化等）。
`filtered_feature_bc_matrix.h5`	与 `filtered_feature_bc_matrix/` 内容相同，但为 HDF5 格式。
`metrics_summary.csv`	以 CSV 格式保存的运行结果汇总指标文件，详见基因表达指标说明页面。
`molecule_info.h5`	包含所有具有有效条形码、有效 UMI，并被高置信度分配到某个基因或 Feature Barcode 的分子级别信息。该文件是运行 `cellranger aggr` 所需的输入文件。
`possorted_genome_bam.bam`	经过基因组和转录组比对后按基因组位置排序的 BAM 文件（已建立索引），包含已比对和未比对的 reads，并带有条形码注释信息。

文件/文件夹	描述
`possorted_genome_bam.bam.bai`	`possorted_genome_bam.bam` 的索引文件。如果参考转录组来源的基因组染色体非常长（>512 Mbp），Cell Ranger v7.0 及以上版本会生成 `possorted_genome_bam.bam.csi` 索引文件。
`raw_feature_bc_matrix/`	包含所有检测到的条形码（包括非细胞条形码），采用 MEX 格式。矩阵中的每个元素表示某个特征（行）与某个条形码（列）对应的 UMI 数量。
`raw_feature_bc_matrix_h5`	与 `raw_feature_bc_matrix/` 内容相同，但为 HDF5 格式。
`web_summary.html`	以 HTML 格式展示的运行结果汇总指标与图表页面，详见 count 的 web summary 页面说明。

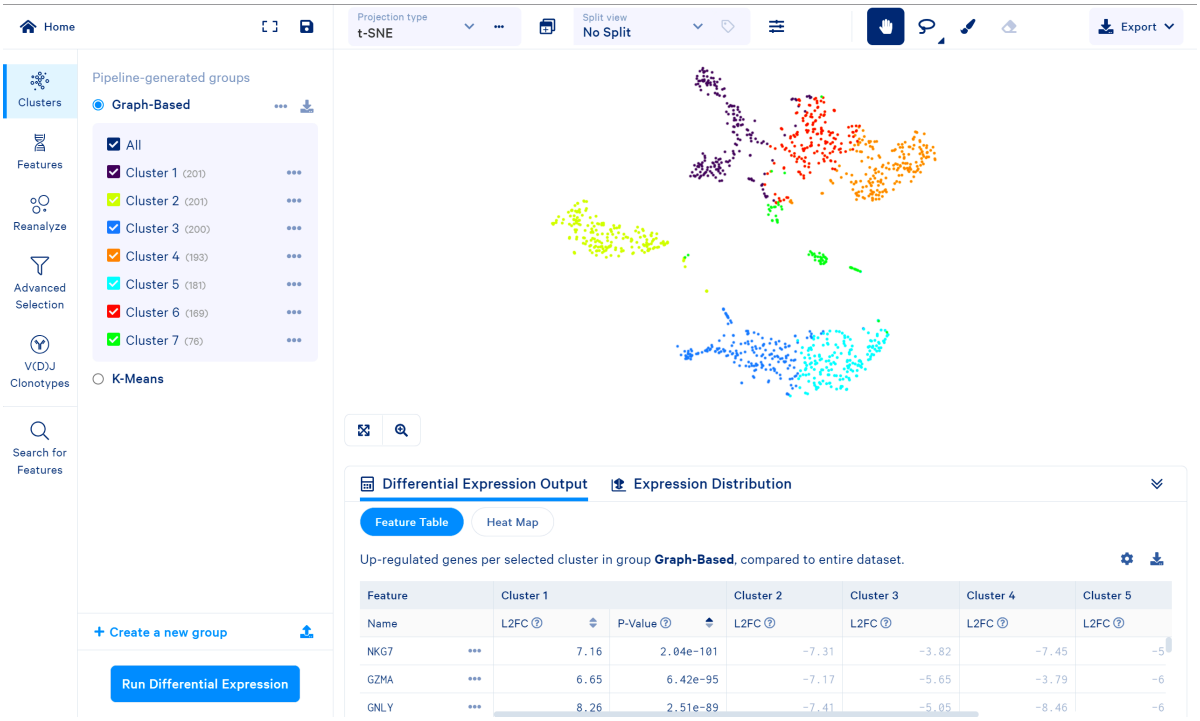
上述文件中中最重要的是`filtered_feature_bc_matrix/`和`filtered_feature_bc_matrix.h5`，这是上游分析得到的主要结果，**作为下游分析的输入的表达矩阵文件。**具体可查看官网相关页面。

`web_summary.html`是上游分析结果用于展示的html文件。可以直接使用浏览器打开，效果如下：



.cloupe文件是一个可以用10X官方可视化软件**Loupe Browser**打开的可视化分析文件，可以按照**教程**对该文件进行探索。

> Loupe Browser 是一款功能强大的可视化软件，为用户提供直观易用的功能，用于探索和分析 10x Genomics Chromium 和 Visium 数据。你还可以使用 LoupeR 软件包将 Seurat 对象转换为 Loupe Browser 文件格式。



> **Note**
>
> 也可以使用10X提供的[loupeR包]在R中将seurat对象储存为.loupe文件再在Loupe Browser中进行可视化分析，这一方法**仅适用于10X来源的数据**

6 细胞自动注释

cellranger在v9版本引入了[细胞自动注释功能]，可基于`cellranger count`的结果使用`cellranger annotate`对细胞进行自动注释。

> **Important**
>
> 在运行该命令前需要在[10X云分析网站]获取用户token令牌，复制该令牌，随后在命令行中敲入`cellranger cloud auth setup`后输入令牌进行验证

参考命令如下：

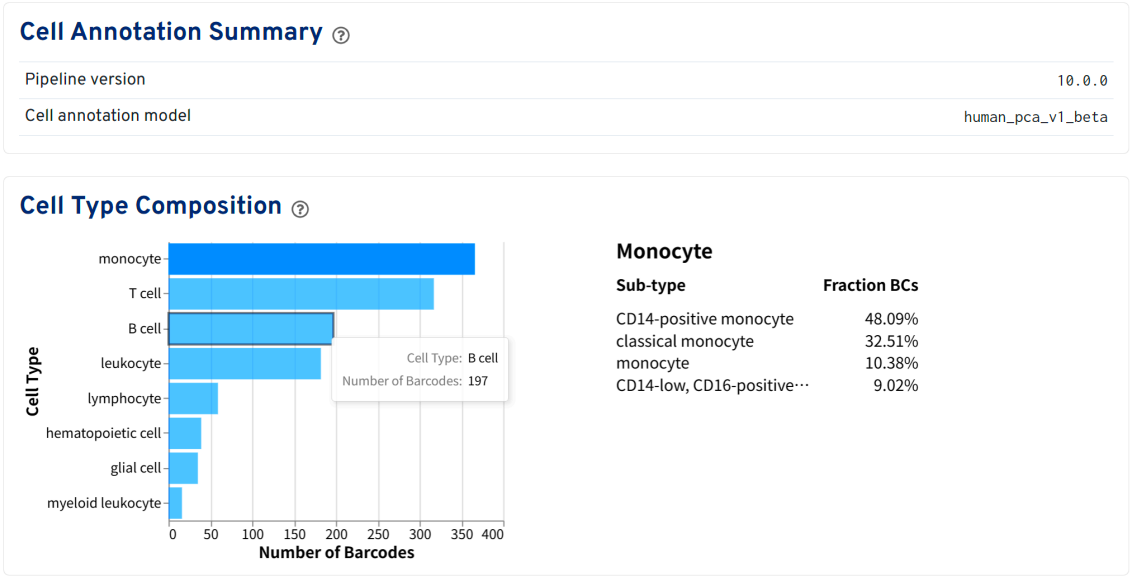
```
cellranger annotate --id=run_annotate_1kpbmcs \
    --matrix=run_count_1kpbmcs/outs/filtered_feature_bc_matrix.h5 \
    --cloupe=run_count_1kpbmcs/outs/cloupe.cloupe \
    --cell-annotation-model=auto \
    --localcores 48 \
    --localmem 1000
```

使用`cellranger cloud annotation models`命令可查看支持的模型，目前仅支持对人或小鼠的数据进行自动注释，参数值直接用auto即可。

输出结果如下：

```
$ ll  run_annotate_1kpbmcs/outs -h
total 49M
-rw-rw-r-- 1 ouyjh ouyjh  14M Mar  4 16:28 cell_annotation_differential_expression.csv
-rw-rw-r-- 1 ouyjh ouyjh 465K Mar  4 16:27 cell_annotation_results.json.gz
-rw-rw-r-- 1 ouyjh ouyjh  31M Mar  4 16:28 cell_annotation_sample_cloupe.cloupe
-rw-rw-r-- 1 ouyjh ouyjh  87K Mar  4 16:28 cell_types.csv
-rw-rw-r-- 1 ouyjh ouyjh 4.4M Mar  4 16:28 web_summary_cell_types.html
```

其中网页报告文件web_summary_cell_types.html的展示效果如下：



官网给出了全部输出结果解释，虽然该注释流程不能完全代替更加精准的手动注释流程，但也具有一定的参考价值。

7 使用示例

本教程的运行使用示例在fat02服务器，路径如下：

```
/oldhome/ouyjh/workspace/scRNA_cellranger_pipeline
```